Klasyfikacja – Notatki z wykładu (tłumaczenie PL)

Materiał źródłowy: Dr. Brian Mc Ginley (Week 3 - Classification.pdf) · Tłumaczenie: Marcin
13 października 2026

Slajdy są w kolejności wykładu. Elementy graficzne, których nie da się przepisać (wykresy, zdjęcia), są opisane w nawiasach kwadratowych. Wzory matematyczne i fragmenty kodu pozostawiono w oryginalnej notacji.

1. Klasyfikacja (*Classification*)

- Dr. Brian Mc Ginley

> *[Slajd tytułowy: tytuł „CLASSIFICATION” na szarym, teksturowanym tle; w prawym dolnym rogu czerwone kółko.]*

2. Klasyfikacja

- Teraz inne problemy:
  - W regresji zakładaliśmy, że na podstawie wejścia wyznaczamy wielkość liczbową: jaką liczbę (wartość ciągłą) przewidujemy dla y (blisko prawdziwej) dla danego wejścia?
  - Wiele problemów ML ma bardziej ograniczony zbiór wyników. Często pytanie brzmi raczej: do której grupy (najprawdopodobniej) należy to wejście?
- To są problemy klasyfikacji.
- Nasze wyjścia będą ograniczone do możliwych klas w danym problemie, tzn. dla n próbek i K kategorii przewidujemy wektor n wartości wybranych spośród C_1, C_2, …, C_k.
- Nasze wejścia pozostają takie same: macierz liczb o wymiarach $n \times m$ (dla n próbek i m cech).

3. Klasyfikacja (2)

- Przykładowe problemy, które można traktować jako klasyfikację:
  - Czy ten e-mail to spam? (2 kategorie)
  - Czy ta transakcja kartą kredytową to oszustwo? (2 kategorie)
  - Czy ta próbka biologiczna jest złośliwa czy łagodna? (2 kategorie)
  - Jakie (angielskie) słowo użytkownik powiedział do mikrofonu? (≈470 tys. kategorii)
  - Na jaki dzień przypadnie Wielkanoc w przyszłym roku? (<< 365 kategorii) A może to jest regresja?
  - Ile osób jest na tym zdjęciu? Kim są te osoby?
  - Mając wartość koloru RGB, jakie słowo opisuje ten kolor?
  - Mając obserwacje pogodowe, czy potrafisz zgadnąć, na jakie miasto patrzymy?

4. Modelowanie (*Modelling*)

- Istnieje wiele sposobów modelowania klasyfikacji.
- Wszystkie wykonują to samo podstawowe zadanie:
  1. Trenowanie na znanych danych
  2. Przewidywanie poprawnej kategorii dla innych, nieznanych wejść.

```
model = SomeClassifierModel(....)
model.fit(X_train, y_train)
y_predicted = model.predict(X_test)
somehowcompareresults(y_test, y_predicted)
```

- (Często stosuje się walidację (*validation*), aby wybrać najlepszą postać klasyfikatora; wcześniej używaliśmy

```
model = LinearRegression(....)
```

- cała idea w kodzie jest w gruncie rzeczy taka sama)

5. Ocena jakości klasyfikacji (*Evaluating Classification Performance*)

- Do oceny algorytmów klasyfikacji często po prostu sprawdza się, jak trafne są predykcje na zbiorze testowym (*test set*)

```
y_pred = model.predict(X_test)
from sklearn.metrics import accuracy_score
accuracy_score(y_test, y_pred)
```

- Daje wynik (< 1), który jest odsetkiem poprawnych predykcji.
- Powyższy kod przechowuje predykcje y osobno (co może się później przydać), ale sam model ma metodę, której można użyć, jeśli potrzebujemy tylko wyniku trafności (*accuracy*)

```
model.score(X_test, y_test)
```

- Ta jedna linijka wykonuje predykcję i porównanie predykcji w jednym kroku. Wrócimy do tego później, omawiając alternatywy.

6. Klasyfikacja binarna (*Binary Classification*)

- Definicja:
- Problem klasyfikacji binarnej ma:
  - Klasę negatywną (*Negative Class*)
  - Klasę pozytywną (*Positive Class*)

```
y ∈ [0, 1] lub y ∈ [−1, 1]
```

- Problemy wieloklasowe (*Multi-class*) rozważymy później.
- Niektóre modele potrafią bezpośrednio obsłużyć wiele klas (Naive Bayes, *k* najbliższych sąsiadów – *k-nearest neighbours*), podczas gdy inne są z natury binarne, ale można je „rozszerzyć” (SVM, regresja logistyczna – *Logistic Regression*).

7. Kategorialna zmienna odpowiedzi (*Categorical Response Variable*)

- Metody stosowane, gdy zmienna odpowiedzi (ŷ) ma określoną liczbę możliwych wyników:
  - klient kupuje lub nie kupuje produktu,
  - pacjent żyje lub umiera,
  - albo kandydat przyjmuje lub odrzuca ofertę pracy.
- Ogólnie dwa wyniki zmiennej odpowiedzi nazywamy „sukcesem” (*success*) i „porażką” (*failure*) i reprezentujemy je jako 1 i 0.
  - Średnia jest wtedy odsetkiem jedynek.