

Machine Learning – Lecture 1 Notes (EN / PL)

Sep 26, 2026 · @Marcin

English version

Slides are in lecture order (video timestamps in brackets). Visuals that cannot be retyped are described in square brackets.

1. What is Machine Learning (ML)? (1:16)

- Algorithms that automatically improve performance through experience
 - Often this means defining a model by hand, and using data to fit its parameters
- There are problems that are difficult for humans but easy for computers
 - E.g. calculating large arithmetic problems
- And there are problems easy for humans but difficult for computers
 - E.g. recognising a picture of a person from the side
- Machine Learning often tries to leverage the things computers are good at (large arithmetic and repetitive problems) to solve things that we are usually able to do more easily.

2. Why ML? (3:56)

- The real world is complex, so it is difficult to hand-craft solutions.
 - Think about how many "if" statements would be needed!
- ML is the preferred framework for applications in many fields:
 - Computer Vision
 - Natural Language Processing
 - Speech Recognition
 - Robotics
- Humans can typically parse sentences, but computers do not get the context.
 - Humans are not consistent with grammar etc., but computers expect consistency.

3. Basic Idea of All Machine Learning (6:07)

- Machine Learning is using an **algorithm** that can learn from **data**.

- We want to create a **model** that takes input and gives output. It is basically: $y = f(x)$
- We figure out the right-hand side of the equation by gathering a lot of data and making the parameters best fit our base model.

4. Basic Example (8:02)

- Take a base model of $y = w_0 + w_1 \cdot x$. We need to work out the "best" w_0 and w_1 parameters.
- Equation of a line: $y = mx + c$
- [Scatter plot: number of friends (x) vs daily minutes online (y); best fit line $Y = 0.9039X + 22.95$]
- Of course, our base model can be much more complicated and have many more parameters that need to be learnt, but the basic idea is the same.
- After we have made the model, we can then make **predictions** in the future. Above, how many daily minutes do we predict for a person with 30 friends on the platform?

5. Why Does It Take So Long? (1) (11:37)

- In the above example (one parameter, a basic line as the model), learning all the parameters is very, very quick. But the real world is not that quick.
- Some ML models can take hours, days, weeks or even months to be trained.
 - ChatGPT is actually 8 different models, with 220 billion parameters in each. This takes a very long time to figure out.

6. Why Does It Take So Long? (2) (12:28)

- The training is repeatedly doing the same procedure over and over again, until we get the parameters we think are best.
- [xkcd comic: an ML system shown as a pile of linear algebra that you "stir" until the answers look right]

7. Gathering Data (14:50)

- Most of the data we want needs to be *labelled*. This means any data we put into the system is a pair of information: y, x
 - where y is the correct answer for each x (which is the collection of all features)
- So, let's say we have a collection of images that are cats or dogs, and we want to build a model that can separate them.

- For a particular image there is a correct y , i.e. y is cat or dog. Then x is all the features of the image, i.e. each x will be the pixel values.

8. Dataset Example (17:44)

- We (the human intelligence) must do a lot of work here.
- We need lots of training data and labels associated with them.
- Example: MNIST data set.
 - To learn to recognise handwritten letters, the algorithm must be trained on 60,000 samples, each of which must be labelled correctly, by hand.
- Sample of data set, from Wikipedia. [grid of handwritten digits 0-9]

9. Hand-Written Digit Recognition (1) (19:55)

- Now let's look at some potential applications and how we could try "phrasing" the problem.
- It is difficult to hand-craft rules about digits. [examples of messy handwritten digits]

10. Hand-Written Digit Recognition (2) (20:59)

- $x_i = [\text{image of a "4"}]$, $y_i = (0, 0, 0, 0, 1, 0, 0, 0, 0, 0)$
- So, the image can be represented by the value of each pixel. Each pixel colour is called a *feature*, and features are independent variables.
 - Represent the input image as a vector $x_i \in \mathbb{R}^{784}$
 - Suppose we have a target vector t_i
 - This is **supervised learning**
 - A discrete, finite label set makes it a **classification** problem.
 - Given a **training set** $\{(x_1, y_1), \dots, (x_N, y_N)\}$, the learning problem is to construct a "good" function $y = f(x)$ from these.
 - $f: \mathbb{R}^{784} \rightarrow \mathbb{R}^{10}$
- Some algorithms will not return exactly $(0, 0, 0, 1, \dots)$ but may return probabilities like $(0.01, 0.03, 0.04, \dots, 0.01, 0.88 \dots)$, so the image is most *likely* a 4.

11. Face Detection (23:40)

- [photos with detected faces boxed; Schneiderman and Kanade, IJCV 2002]
- **Classification** problem.

- $t_i \in \{0, 1, 2\}$: non-face, frontal face, profile face.
- Of course, this can be expanded to the face of a particular person, so the possible t_i set could be large.
 - i.e. t_i is the set of ALL possible results.
- We **map/transform** the image to a particular t_i .

12. Stock Price Prediction (25:53)

- Problems in which t_i is continuous are called **regression**.
- E.g. t_i is the stock price, and x_i contains company profit, debt, cash flow, gross sales, number of spam emails sent, ...
- [chart: S&P/TSX Composite, May 2006 – Apr 2008]

13. Users of ML (27:22)

- [Logos: Amazon, Netflix, Microsoft, Yahoo!, Gmail, Facebook, Google. Images: CCTV camera, shop receipt, self-driving car, patient vital-signs monitor, brain scans, DNA, video game]

14. High-Profile Examples: Target (29:13)

- Forbes (Kashmir Hill, 16/02/2012): "How Target Figured Out A Teen Girl Was Pregnant Before Her Father Did"

15. High-Profile Examples: Netflix (30:21)

- Salon (Andrew Leonard): "How Netflix is turning viewers into puppets". The piece argues that "House of Cards" was built from what Big Data says viewers want.

16. High-Profile Examples: Object Recognition (31:05)

- Deep Learning for Object Recognition: Hinton & colleagues, NIPS 2012
- [8 images with the model's top-5 predicted labels, e.g. mite, container ship, motor scooter, leopard]

17. High-Profile Examples: AlphaGo (31:55)

- Learns to play the game Go just by playing games against itself
- Starting from completely random play: <https://deepmind.com/blog/alphago-zero-learning-scratch/>

18. High-Profile Examples: AI Art (32:46)

- Smithsonian SmartNews: "Christie's Is First to Sell Art Made by Artificial Intelligence, But What Does That Mean?"
- Paris-based art collective Obvious' "Portrait of Edmond Belamy" sold for \$432,500, nearly 45 times its initial estimate.

19. High-Profile Examples: Generative AI (33:08)

- DALL-E
- ChatGPT
- Gemini
- Midjourney
- Etc.

20. Supervised Learning (34:03)

- Techniques where we have training examples where we **know** the correct result (the y values). Different types of supervised learning are:
 - Classification
 - Regression
- Some algorithms:
 - Linear/Logistic Regression
 - Naive Bayes
 - k-Nearest Neighbours
 - Support Vector Machines
 - Neural Networks
 - Decision Trees
 - Random Forests

21. Unsupervised Learning (34:28)

- Techniques where there is no "right" answer known, but the algorithm tries to find some **structure/patterns** in the data.
 - Principal Component Analysis (Dimensionality Reduction)
 - k-means Clustering
 - PageRank (Google)

- Unsupervised learning techniques will group things together, but we do not necessarily know what the groups are.
- We will do less unsupervised learning in this module.

22. Other Types (36:06)

- There are other types of Machine Learning, e.g. Reinforcement Learning.
 - (outside the scope of this module)

23. Types of Machine Learning (36:29)

- **Machine Learning**
 - **Supervised Learning**
 - Classification [plot: two groups of points and an unknown point to assign to one of them]
 - Regression [plot: points with a fitted trend line]
 - **Unsupervised Learning**
 - Clustering [plot: points grouped into two clusters]
 - Association [shapes linked by arrows to show relationships between items]
 - **Reinforcement Learning**

24. Machine Learning (37:23)

- Often referred to as narrow AI.
- We are only concerned with a specific task.
- So the goal of machine learning is not to develop general intelligence or a universal learning algorithm.
- Machine learning seeks an algorithm that learns a particular task well,
- and that should result in a system that probably carries out the task correctly on most occasions.

25. What Do We Need to Do Machine Learning? (38:03)

- **The Task:** define or limit the task.
- **The Experience:** this is the data; more data = more experience.
- **The Performance Measure:** we need a good way to measure this.
- **The Learning Algorithm:** the recipe by which we will improve our performance.

- **The Intelligence:** the network, i.e. the brain.

Wersja polska

Slajdy są w kolejności wykładu (znaczniki czasu nagrania w nawiasach). Elementów graficznych, których nie da się przepisać, dotyczą opisy w nawiasach kwadratowych.

1. Czym jest uczenie maszynowe (ML)? (1:16)

- Algorytmy, które automatycznie poprawiają swoje działanie dzięki doświadczeniu
 - Często oznacza to ręczne zdefiniowanie modelu i dopasowanie jego parametrów na podstawie danych
- Istnieją problemy trudne dla ludzi, ale łatwe dla komputerów
 - Np. obliczanie dużych działań arytmetycznych
- Istnieją też problemy łatwe dla ludzi, ale trudne dla komputerów
 - Np. rozpoznanie osoby na zdjęciu z profilu
- Uczenie maszynowe często wykorzystuje to, w czym komputery są dobre (duże obliczenia i powtarzalne zadania), aby rozwiązywać problemy, które nam zwykle przychodzą łatwiej.

2. Dlaczego ML? (3:56)

- Świat rzeczywisty jest złożony, więc trudno ręcznie tworzyć rozwiązania.
 - Pomyśl, ile instrukcji „if” byłoby potrzebnych!
- ML to preferowane podejście w wielu dziedzinach:
 - Widzenie komputerowe (Computer Vision)
 - Przetwarzanie języka naturalnego (NLP)
 - Rozpoznawanie mowy
 - Robotyka
- Ludzie zwykle potrafią zrozumieć zdania, ale komputery nie łapią kontekstu.
 - Ludzie nie są konsekwentni w gramatyce itp., a komputery oczekują spójności.

3. Podstawowa idea całego uczenia maszynowego (6:07)

- Uczenie maszynowe to użycie **algorytmu**, który potrafi uczyć się z **danych**.
- Chcemy stworzyć **model**, który przyjmuje wejście i zwraca wyjście. W skrócie: $y = f(x)$

- Prawą stronę równania ustalamy, zbierając dużo danych i dobierając parametry tak, by jak najlepiej pasowały do modelu bazowego.

4. Prosty przykład (8:02)

- Weźmy model bazowy $y = w_0 + w_1 \cdot x$. Musimy znaleźć „najlepsze” parametry w_0 i w_1 .
- Równanie prostej: $y = mx + c$
- [Wykres punktowy: liczba znajomych (x) a dzienne minuty online (y); prosta najlepszego dopasowania $Y = 0,9039X + 22,95$]
- Oczywiście model bazowy może być dużo bardziej złożony i mieć znacznie więcej parametrów do nauczenia, ale idea jest ta sama.
- Gdy mamy już model, możemy robić **predykcje** na przyszłość. Ile minut dziennie przewidujemy dla osoby z 30 znajomymi na platformie?

5. Dlaczego to trwa tak długo? (1) (11:37)

- W powyższym przykładzie (jeden parametr, prosta jako model) nauczenie wszystkich parametrów jest bardzo, bardzo szybkie. W realnym świecie tak szybko nie jest.
- Trenowanie niektórych modeli ML może trwać godziny, dni, tygodnie, a nawet miesiące.
 - ChatGPT to w rzeczywistości 8 różnych modeli, każdy z 220 miliardami parametrów. Ich wyznaczenie zajmuje bardzo dużo czasu.

6. Dlaczego to trwa tak długo? (2) (12:28)

- Trening polega na powtarzaniu tej samej procedury w kółko, aż uzyskamy parametry, które uznamy za najlepsze.
- [Komiks xkcd: system ML jako sterta algebry liniowej, którą „mieszasz”, aż odpowiedzi zaczną wyglądać dobrze]

7. Zbieranie danych (14:50)

- Większość potrzebnych danych musi być *oznaczona etykietami*. Oznacza to, że każda dana wprowadzana do systemu to para informacji: y, x
 - gdzie y to poprawna odpowiedź dla każdego x (x to zbiór wszystkich cech)
- Załóżmy, że mamy zbiór zdjęć kotów i psów i chcemy zbudować model, który je rozdzieli.
- Dla konkretnego zdjęcia istnieje poprawne y , czyli kot lub pies. x to wszystkie cechy zdjęcia, czyli wartości pikseli.

8. Przykładowy zbiór danych (17:44)

- My (ludzka inteligencja) musimy tu wykonać dużo pracy.
- Potrzebujemy dużo danych treningowych wraz z przypisanymi etykietami.
- Przykład: zbiór danych MNIST.
 - Aby nauczyć się rozpoznawać odręczne litery, algorytm musi zostać wytrenowany na 60 000 próbek, z których każda musi być poprawnie oznaczona ręcznie.
- Próbką zbioru danych, z Wikipedii. [siatka odręcznych cyfr 0–9]

9. Rozpoznawanie odręcznych cyfr (1) (19:55)

- Przyjrzyjmy się potencjalnym zastosowaniom i temu, jak można „sformułować” problem.
- Trudno ręcznie stworzyć reguły opisujące cyfry. [przykłady niewyraźnych odręcznych cyfr]

10. Rozpoznawanie odręcznych cyfr (2) (20:59)

- $x_i = [\text{obraz cyfry „4”}]$, $y_i = (0, 0, 0, 0, 1, 0, 0, 0, 0, 0)$
- Obraz można przedstawić jako wartości poszczególnych pikseli. Kolor każdego piksela nazywamy *cechą*, a cechy są zmiennymi niezależnymi.
 - Obraz wejściowy reprezentujemy jako wektor $x_i \in \mathbb{R}^{784}$
 - Załóżmy, że mamy wektor docelowy t_i
 - To jest **uczenie nadzorowane**
 - Dyskretny, skończony zbiór etykiet oznacza problem **klasyfikacji**.
 - Mając **zbiór treningowy** $\{(x_1, y_1), \dots, (x_N, y_N)\}$, problem uczenia polega na zbudowaniu z nich „dobrej” funkcji $y = f(x)$.
 - $f: \mathbb{R}^{784} \rightarrow \mathbb{R}^{10}$
- Niektóre algorytmy nie zwrócą dokładnie $(0, 0, 0, 1, \dots)$, lecz prawdopodobieństwa, np. $(0,01; 0,03; 0,04; \dots; 0,01; 0,88 \dots)$, więc obraz to *najprawdopodobniej* 4.

11. Wykrywanie twarzy (23:40)

- [zdjęcia z zaznaczonymi twarzami; Schneiderman i Kanade, IJCV 2002]
- Problem **klasyfikacji**.
- $t_i \in \{0, 1, 2\}$: brak twarzy, twarz en face, twarz z profilu.

- Można to rozszerzyć na twarz konkretnej osoby, wtedy zbiór możliwych t_i może być duży.
 - Czyli t_i to zbiór WSZYSTKICH możliwych wyników.
- **Odwzorowujemy/przekształcamy** obraz na konkretne t_i .

12. Predykcja cen akcji (25:53)

- Problemy, w których t_i jest ciągłe, nazywamy **regresją**.
- Np. t_i to cena akcji, a x_i zawiera zysk firmy, zadłużenie, przepływy pieniężne, sprzedaż brutto, liczbę wysłanych maili ze spamem, ...
- [wykres: indeks S&P/TSX Composite, maj 2006 – kwiecień 2008]

13. Użytkownicy ML (27:22)

- [Logotypy: Amazon, Netflix, Microsoft, Yahoo!, Gmail, Facebook, Google. Obrazy: kamera monitoringu, paragon sklepowy, samochód autonomiczny, monitor funkcji życiowych pacjenta, skany mózgu, DNA, gra komputerowa]

14. Głośne przykłady: Target (29:13)

- Forbes (Kashmir Hill, 16.02.2012): „Jak Target odkrył, że nastolatka jest w ciąży, zanim dowiedział się o tym jej ojciec”

15. Głośne przykłady: Netflix (30:21)

- Salon (Andrew Leonard): „Jak Netflix zamienia widzów w marionetki”. Artykuł twierdzi, że „House of Cards” zbudowano na tym, czego według Big Data chcą widzowie.

16. Głośne przykłady: rozpoznawanie obiektów (31:05)

- Deep Learning w rozpoznawaniu obiektów: Hinton i współpracownicy, NIPS 2012
- [8 zdjęć z 5 najbardziej prawdopodobnymi etykietami modelu, np. roztocz, kontenerowiec, skuter, lampart]

17. Głośne przykłady: AlphaGo (31:55)

- Uczy się gry w Go wyłącznie przez rozgrywanie partii przeciwko sobie
- Zaczynając od całkowicie losowej gry: <https://deepmind.com/blog/alphago-zero-learning-scratch/>

18. Głośne przykłady: sztuka AI (32:46)

- Smithsonian SmartNews: „Christie's jako pierwszy sprzedaje dzieło stworzone przez sztuczną inteligencję. Co to oznacza?”
- „Portret Edmonda Belamy'ego” paryskiego kolektywu Obvious sprzedano za 432 500 USD, prawie 45 razy powyżej początkowej wyceny.

19. Głośne przykłady: generatywna AI (33:08)

- DALL-E
- ChatGPT
- Gemini
- Midjourney
- Itd.

20. Uczenie nadzorowane (34:03)

- Techniki, w których mamy przykłady treningowe ze **znanym** poprawnym wynikiem (wartości y). Rodzaje uczenia nadzorowanego:
 - Klasyfikacja
 - Regresja
- Przykładowe algorytmy:
 - Regresja liniowa/logistyczna
 - Naiwny klasyfikator Bayesa
 - k-najbliższych sąsiadów (k-NN)
 - Maszyny wektorów nośnych (SVM)
 - Sieci neuronowe
 - Drzewa decyzyjne
 - Lasy losowe

21. Uczenie nienadzorowane (34:28)

- Techniki, w których nie znamy „prawidłowej” odpowiedzi, a algorytm próbuje znaleźć w danych jakąś **strukturę/wzorce**.
 - Analiza głównych składowych, PCA (redukcja wymiarowości)
 - Klasteryzacja k-średnich (k-means)
 - PageRank (Google)

- Techniki uczenia nienadzorowanego grupują obiekty, ale niekoniecznie wiemy, czym są te grupy.
- W tym module będzie mniej uczenia nienadzorowanego.

22. Inne rodzaje (36:06)

- Istnieją inne rodzaje uczenia maszynowego, np. uczenie ze wzmocnieniem (Reinforcement Learning).
 - (poza zakresem tego modułu)

23. Rodzaje uczenia maszynowego (36:29)

- **Uczenie maszynowe**
 - **Uczenie nadzorowane**
 - Klasyfikacja [wykres: dwie grupy punktów i nieznany punkt do przypisania do jednej z nich]
 - Regresja [wykres: punkty z dopasowaną linią trendu]
 - **Uczenie nienadzorowane**
 - Klasteryzacja [wykres: punkty pogrupowane w dwa skupiska]
 - Asocjacja [figury połączone strzałkami, pokazujące powiązania między elementami]
 - **Uczenie ze wzmocnieniem**

24. Uczenie maszynowe (37:23)

- Często nazywane „wąską AI” (narrow AI).
- Interesuje nas wyłącznie konkretne zadanie.
- Celem uczenia maszynowego nie jest więc stworzenie ogólnej inteligencji ani uniwersalnego algorytmu uczącego się.
- Uczenie maszynowe szuka algorytmu, który dobrze nauczy się konkretnego zadania,
- i powinno dać system, który prawdopodobnie wykona zadanie poprawnie w większości przypadków.

25. Czego potrzebujemy, by stosować uczenie maszynowe? (38:03)

- **Zadanie:** zdefiniuj lub ogranicz zadanie.
- **Doświadczenie:** to są dane; więcej danych = więcej doświadczenia.

- **Miara skuteczności:** potrzebujemy dobrego sposobu jej pomiaru.
- **Algorytm uczący:** przepis, według którego poprawiamy skuteczność.
- **Inteligencja:** sieć, czyli „mózg”.

Exam notes / Uwagi do egzaminu

Eight points on the slides are wrong or need a caveat.

- **Slide 4:** the slide text has a word missing (“we need to out the best”). I filled it in as “work out”.
- **Slide 5:** the slide says “one parameter”, but the line model has two (w_0 and w_1).
- **Slide 5:** “8 models × 220B parameters” is a 2023 leak about GPT-4. OpenAI never confirmed it, so don't quote it as fact.
- **Slide 8:** MNIST contains handwritten **digits**, not letters.
- **Slide 21:** the slide says “k-mean”. The correct name is **k-means**.
- **Slide 21:** PageRank is a graph-ranking algorithm (link analysis), not classic unsupervised learning. If an exam asks for examples, use k-means, PCA or hierarchical clustering.
- **Slide 24:** “probably... on most occasions” most likely refers to PAC learning (*Probably Approximately Correct*).
- **Slide 25:** “The Intelligence – the Network” applies to neural networks. More generally, this is **the model**, which can also be a decision tree, an SVM, and so on.