Regresja logistyczna – Notatki z wykładu (tłumaczenie PL)

Materiał źródłowy: Dr. Brian Mc Ginley (Week 3 - Classification Logistic Regression.pdf) · Tłumaczenie: Marcin
13 października 2026

Slajdy są w kolejności wykładu. Elementy graficzne, których nie da się przepisać (wykresy, zdjęcia), są opisane w nawiasach kwadratowych. Wzory matematyczne i fragmenty kodu pozostawiono w oryginalnej notacji.

1. Regresja logistyczna (*Logistic Regression*)

Dr. Brian Mc Ginley

2. Regresja logistyczna (2)

- Na początek klasyfikacji: czy naprawdę potrzebujemy innego algorytmu? Zobaczmy, czy da się „podkręcić” to, co wiemy o regresji.
- Uwaga:
  - „Regresja logistyczna” to myląca nazwa, ponieważ nie próbujemy przewidywać wartości ciągłej.
  - Przewidujemy wprawdzie wartość ciągłą (między 0 a 1), ale następnie stosujemy dla niej próg (*threshold*), aby otrzymać wartości dyskretne (nieciągłe).
  - Regresja logistyczna jest w gruncie rzeczy algorytmem klasyfikacji.

3. Regresja logistyczna (3)

- Pomimo nazwy regresja logistyczna jest modelem klasyfikacyjnym ML. Obiekt należy do kategorii 0 albo 1, a *przewidywana* wartość leży między 0 a 1. Przewidywana wartość jest *prawdopodobieństwem (p)*.
- Zmienna odpowiedzi *y* wynosi 0 albo 1. Przy standardowym wzorze regresji:

$$\hat{y} = w_0 + w_1 x_1$$

Oszacowanie ŷ ma duże szanse być <0 lub >1. My chcemy oszacowania *p* mieszczącego się między 0 a 1.

4. Regresja logistyczna (4)

- Dodatkowo (dla jednej cechy) otrzymujemy wykres taki jak:
- Ten wykres wyraźnie nie będzie zbyt dokładny. O wiele bardziej wolelibyśmy wykres taki jak:

> *[Dwa wykresy punktowe po prawej stronie slajdu, oba z osią poziomą „X-Axis” i pionową „Y-Axis” oraz przerywanymi poziomymi liniami na poziomach Y=0 i Y=1. Górny, „Linear Regression”: czerwone punkty leżą w dwóch grupach – sześć na poziomie Y=0 po lewej stronie, sześć na poziomie Y=1 po prawej; przez dane przechodzi prosta, rosnąca ukośna linia, która przekracza poziom Y=1 i schodzi poniżej Y=0. Dolny, „Logistic Regression”: te same dwie grupy czerwonych punktów, ale dopasowana krzywa ma kształt litery S – płasko przy Y=0, gwałtowny wzrost w środku, płasko przy Y=1.]*

5. Model regresji logistycznej (*Model for Logistic Regression*)

- **Funkcja sigmoidalna** (*Sigmoid function*), zwana też funkcją **logistyczną**, przyjmuje dowolną liczbę rzeczywistą i odwzorowuje ją na wartość z przedziału od 0 do 1.
  - Gdy argument dąży do +∞, y dąży do 1, a gdy dąży do −∞, y dąży do 0.

$$y = f(x) = 1 / (1 + e^{-x})$$

> *[Wykres funkcji sigmoidalnej: oś pozioma od −6 do 6, oś pionowa od 0 do 1 (zaznaczone 0,5 przy x = 0); krzywa w kształcie litery S, rosnąca od 0 (dla x ≈ −6) do 1 (dla x ≈ 6), przechodząca przez punkt (0; 0,5).]*

- **Uwaga**: funkcja sigmoidalna jest często używana w sieciach neuronowych i głębokim uczeniu (*Deep Learning*).
- Mamy funkcję, która daje pożądany kształt. Jak powiązać ją z naszym równaniem

```
ŷ = w₀ + w₁x ?
```

6. Model regresji logistycznej (2)

- Przypomnienie: funkcja sigmoidalna odwzorowuje wartość z zakresu od −∞ do +∞ na zakres od 0 do 1.
- Możemy odwzorować nasze ŷ = w₀ + w₁x (które również przyjmuje wartości od −∞ do +∞) za pomocą funkcji sigmoidalnej na zakres od 0 do 1.

```
ŷ = w₀ + w₁x
y = f(x) = 1 / (1 + e⁻ˣ)
y (lub p) = 1 / (1 + e^−(w₀ + w₁x))
```

[Schemat: strzałka prowadzi od równania ŷ = w₀ + w₁x do argumentu x funkcji sigmoidalnej, a od niej kolejna strzałka do wzoru y (lub p) = 1 / (1 + e^−(w₀ + w₁x)), czyli do funkcji sigmoidalnej, w której x zastąpiono przez w₀ + w₁x.]

- Albo w postaci ogólnej:

```
y (lub p) = 1 / (1 + e^−(w₀ + w₁x₁ + ⋯ + wₙxₙ))
```

7. Model regresji logistycznej (3)

- Czasami powyższe równanie:

```
y (lub p) = 1 / (1 + e^−(w₀ + w₁x₁ + ⋯ + wₙxₙ))
```

będzie zapisywane także jako (wrócimy do tego) (gdzie *ln* oznacza logarytm naturalny):

```
ln( p / (1 − p) ) = w₀ + w₁x₁ + ⋯ + wₙxₙ
```

- Nazywa się to **funkcją regresji logistycznej** (*logistic regression function*). W literaturze wagi/współczynniki (w₀ …) są często zapisywane jako (β₀, …, βₙ).

8. Model regresji logistycznej (4)

- Uwaga: we wzorze

  ```
  ln( p / (1 − p) ) = w₀ + w₁x₁ + ⋯ + wₙxₙ
  ```

  - Wyrażenie (p / (1 − p)) potocznie nazywa się szansą (*odds*).
    - Np. drużyna ma 50% szans na wygraną, czyli p = 0,5:

      ```
      p / (1 − p) = 0,5 / 0,5 = 1 : 1
      ```

    - Np. drużyna ma 80% szans na wygraną, czyli p = 0,8:

      ```
      p / (1 − p) = 0,8 / 0,2 = 4 : 1
      ```

    - Np. drużyna ma 5% szans na wygraną, czyli p = 0,05:

      ```
      p / (1 − p) = 0,05 / 0,95 = 0,053 : 1
      ```

- Problem z funkcją szansy jest taki, że jest asymetryczna.
  - Jeśli prawdopodobieństwo wygranej mieści się między 0 a 0,5, szansa będzie między 0 a 1.
  - Jeśli prawdopodobieństwo wygranej mieści się między 0,5 a 1, szansa będzie między 1 a ∞.
    - Problem!

[Wykres w prawym dolnym rogu: oś pozioma – prawdopodobieństwo (zaznaczone ½ i 1), oś pionowa – szansa (odds; zaznaczone „even” oraz ∞). Krzywa jest niemal płaska i bliska zeru dla małych prawdopodobieństw, a po przekroczeniu ½ rośnie coraz szybciej i gwałtownie biegnie ku nieskończoności, gdy prawdopodobieństwo zbliża się do 1.]

9. Model regresji logistycznej (5)

- Aby rozwiązać ten problem asymetrii szansy, często używa się logarytmu funkcji szansy (ponieważ jest to funkcja symetryczna).

```
ln( p / (1 − p) ) = logit(p)
```

- Ta funkcja logitowa (*logit function*) stanowi podstawę regresji logistycznej:

$$\ln\left(\frac{p}{1-p}\right) = w_0 + w_1x_1 + \cdots + w_nx_n$$

- Tak się składa, że funkcją odwrotną do funkcji logitowej jest funkcja sigmoidalna.

> *[Wykres funkcji logit: oś pozioma – p od 0,0 do 1,0, oś pionowa od −6 do 6; krzywa rosnąca w kształcie odwróconej litery S, przechodząca przez punkt (0,5; 0) i dążąca do −∞ przy p → 0 oraz do +∞ przy p → 1. Pozioma pomarańczowa linia zaznacza poziom 0.]*

10. Regresja logistyczna (5)

- Pomimo nazwy regresja logistyczna jest modelem klasyfikacyjnym ML.

> *[Dwa wykresy na niebieskim tle, obok siebie. Lewy, „Linear Regression": białe punkty na poziomach y=0 (po lewej) i y=1 (po prawej); przez nie biegnie prosta rosnąca linia z opisem „Predicted Y can exceed 0 and 1 range". Prawy, „Logistic Regression": te same grupy punktów, krzywa w kształcie litery S z opisem „Predicted Y lies within 0 and 1 range".]*

- Obiekt należy do kategorii 0 albo 1, a *przewidywana* wartość leży między 0 a 1. Przewidywana wartość jest *prawdopodobieństwem*.

11. Granica decyzyjna (*Decision Boundary*)

- Oczekujemy, że klasyfikator da nam zestaw wyników, czyli klas, gdy przepuścimy dane wejściowe przez funkcję predykcji, oraz że zwróci wynik prawdopodobieństwa między 0 a 1.
- Przykład:
  - Mamy 2 klasy: koty i psy (klasa 1: pies (1), klasa 2 – koty (0)). Ustalamy wartość progową: powyżej niej klasyfikujemy obserwacje do klasy 1, a jeśli wartość spadnie poniżej progu, klasyfikujemy ją do klasy 2.
  - Przy progu równym 0,5: jeśli funkcja predykcji zwróciła wartość 0,7, zaklasyfikujemy obserwację do klasy 1 (PIES). Jeśli zwróciła 0,2, zaklasyfikujemy ją do klasy 2 (KOT).
  - Możemy wybrać inną granicę, aby wyregulować kompromis między FP a FN (wyniki fałszywie pozytywne vs fałszywie negatywne).

> *[Wykres funkcji sigmoidalnej: oś pozioma x od −8 do 8, oś pionowa y od 0,0 do 1,0; krzywa w kształcie litery S. Pozioma linia na poziomie y = 0,5 (opisana „0.5") przecina krzywą w punkcie x = 0.]*

12. Próg (*Threshold*)

- Końcowym wynikiem naszego systemu ML (dla klasyfikatora binarnego) jest liczba 0 albo 1.
- Systemy ML często zwracają tylko tę klasę, którą uznają za najbardziej prawdopodobną dzięki temu progowi, tzn. po jednej stronie granicy decyzyjnej zawsze zwracają 0, a po drugiej 1.
- W wielu bibliotekach ML obsługujących regresję logistyczną można pobrać „prawdopodobieństwo" wyniku, jednak niektóre mogą zwracać tylko 0 lub 1.

13. Regresja logistyczna (6)

- Oczywiście jest to system klasyfikacji binarnej, więc co się dzieje, gdy mamy wiele kategorii?
- Na razie przyjmiemy metodę ze scikit-learn za „magię" w kwestii tego, jak radzi sobie z wieloma kategoriami.
- Wersja regresji logistycznej jest bardzo często stosowana w ostatniej warstwie sieci neuronowej, więc jej zrozumienie pomoże, gdy dojdziemy do tego tematu później.

14. Regresja logistyczna (7)

- Zalety:
  - Łatwa interpretacja (*Interpretable*)
  - Mała liczba parametrów
  - Efektywna obliczeniowo w trenowaniu (estymacji wag)
- Wady:
  - Skuteczność niekoniecznie dorównuje najlepszym klasyfikatorom (zawsze zależy od problemu) – czasami jest to właściwy model
    - Lasy losowe (*Random forests*) / drzewa wzmacniane (*boosted trees*), SVM itp. przewyższałyby regresję logistyczną w dużym zbiorze rzeczywistych problemów
- Zastosowania:
  - Biostatystyka i nauki społeczne
  - Podstawa sieci neuronowych / uogólnionych modeli liniowych (*generalised linear models*)